

Hypothesis Platform — Data Assessment v5

Fecha: 2026-05-23 | **Versión:** 5.0 | **Autor:** Data Engineering

Data Vision Statement

El objetivo de la estrategia de datos de Hypothesis no es únicamente medir uso, sino transformar la plataforma en la única herramienta de aprendizaje digital capaz de demostrar impacto educativo y valor institucional de forma cuantificable — convirtiendo analytics en diferencial comercial y motor de retención.

Resumen Ejecutivo

Hypothesis es una plataforma B2B SaaS de anotaciones colaborativas para universidades. Se integra con los principales LMS (Canvas, Blackboard, D2L, Moodle) y permite a estudiantes y profesores anotar cualquier material educativo digital.

Hallazgo central: La compañía posee una arquitectura técnica madura y acumula datos operacionales significativos, pero hoy no puede responder las preguntas más básicas que determinan retención de clientes: *¿cuánto usan Hypothesis los estudiantes? ¿qué instituciones están en riesgo de no renovar?* Esta brecha no es un problema técnico menor — es un riesgo de revenue que se agrava con el tiempo.

Corrección crítica respecto a versiones anteriores: El analytics service marcado como TODO en el código no se implementó en días por los equipos anteriores no por descuido, sino porque el diseño correcto requiere una arquitectura de ingesta dedicada. Escribir eventos de comportamiento de miles de estudiantes simultáneos directo al PostgreSQL transaccional causaría contención que degradaría la API en producción. La Fase 1 del roadmap ha sido recalibrada en consecuencia.

Segunda corrección crítica: La purga de LTI params a 30 días destruye contexto histórico irremplazable (nombre del curso al momento del launch, rol académico, término/semestre, parámetros LMS custom) que no está normalizado en columnas estructurales. Esto es un riesgo **Crítico** que impide los reportes YoY que las universidades necesitan para renovar contratos. Requiere solución de ingeniería inmediata (ver R4).

Stack corregido: La propuesta de infraestructura analítica ha sido rediseñada para optimizar el stack AWS existente (ElasticBeanstalk + RDS + S3) en lugar de introducir herramientas externas sin justificación de costos (ver Bloque 5).

Estado Actual

Área	Estado	Descripción
Infraestructura	Sólida	AWS multi-región, PostgreSQL, Elasticsearch, RabbitMQ en producción
Integraciones	Sólidas	Canvas, Blackboard, D2L, Moodle, JSTOR, VitalSource, YouTube, HubSpot
Modelo de datos	Maduro	61 tablas, 174+134 migraciones, esquema bien normalizado
Analytics	Parcial	Solo métricas LTI (launches, grades). Sin engagement real
Tracking	Deficiente	Analytics service sin implementar. Sin sesiones ni apertura de recursos
Data Quality	Pendiente	Queries listas para ejecutar — ver sección Volumetría Real
Data Governance	Inexistente	Sin data catalog, sin ownership formal, sin definiciones compartidas
Revenue Analytics	Inexistente	Datos de contratos y billing desconectados de datos de uso
Product Analytics	Inexistente	No existe una capa de analytics de producto

Madurez global estimada: 1.6 / 5. El roadmap de este documento está diseñado para llevarla a 3.5/5 en 12 meses.

Volumetría Real

⚠ Esta sección debe completarse antes de presentar el documento al CEO o solicitar presupuesto para Fase 1. Ejecutar las queries en producción y completar los valores. Sin números reales, este diagnóstico es una hipótesis, no un diagnóstico de ingeniería.

Queries a ejecutar — BD h (PostgreSQL)

```
-- 1. Total de anotaciones activas
SELECT COUNT(*) AS total_anotaciones
FROM annotation WHERE deleted = false;
-- RESULTADO: [COMPLETAR]

-- 2. Crecimiento mensual de anotaciones (últimos 24 meses)
SELECT
    DATE_TRUNC('month', created) AS mes,
    COUNT(*) AS anotaciones,
    COUNT(DISTINCT userid) AS usuarios_activos,
    COUNT(*) FILTER (WHERE array_length(references, 1) > 0) AS replies
FROM annotation
WHERE deleted = false AND created > NOW() - INTERVAL '24 months'
GROUP BY 1 ORDER BY 1 DESC;
-- RESULTADO: [COMPLETAR - tabla de 24 filas]

-- 3. Usuarios activos (30/90/180 días)
SELECT
    COUNT(DISTINCT userid) FILTER (WHERE created > NOW() - INTERVAL '30 days') AS mau_30d,
    COUNT(DISTINCT userid) FILTER (WHERE created > NOW() - INTERVAL '90 days') AS mau_90d,
    COUNT(DISTINCT userid) FILTER (WHERE created > NOW() - INTERVAL '180 days') AS mau_180d
FROM annotation WHERE deleted = false;
-- MAU 30d: [COMPLETAR] | MAU 90d: [COMPLETAR] | MAU 180d: [COMPLETAR]

-- 4. Tamaño de la base de datos y tablas más grandes
SELECT pg_size_pretty(pg_database_size(current_database())) AS tamano_bd_h;
-- RESULTADO: [COMPLETAR] GB

SELECT relname, pg_size_pretty(pg_total_relation_size(relid)) AS tamano, n_live_tup AS filas
FROM pg_stat_user_tables ORDER BY pg_total_relation_size(relid) DESC LIMIT 10;
-- RESULTADO: [COMPLETAR - top 10 tablas por tamaño]

-- 5. Anotaciones públicas vs privadas (shared)
SELECT shared, COUNT(*) FROM annotation WHERE deleted = false GROUP BY 1;
-- RESULTADO: shared=true [COMPLETAR] | shared=false [COMPLETAR]
```

Queries a ejecutar — BD `lms` (PostgreSQL)

```
-- 6. Instituciones por estado de actividad
SELECT
    COUNT(*) FILTER (WHERE last_launched > NOW() - INTERVAL '90 days') AS activas_90d,
    COUNT(*) FILTER (WHERE last_launched > NOW() - INTERVAL '180 days') AS activas_180d,
    COUNT(*) FILTER (WHERE last_launched ≤ NOW() - INTERVAL '180 days') AS inactivas,
    COUNT(*) AS total
FROM application_instances;
-- Activas 90d: [COMPLETAR] | Activas 180d: [COMPLETAR] | Inactivas: [COMPLETAR] | Total:
[COMPLETAR]

-- 7. Cursos y usuarios
SELECT
    COUNT(DISTINCT lc.id) AS total_cursos,
    COUNT(DISTINCT lu.id) AS total_usuarios_lms
FROM lms_course lc, lms_user lu;
-- Cursos totales: [COMPLETAR] | Usuarios LMS: [COMPLETAR]

-- 8. Eventos por tipo y tendencia mensual (últimos 12 meses)
SELECT
    DATE_TRUNC('month', e.timestamp) AS mes,
    et.type AS tipo_evento,
    COUNT(*) AS cantidad,
    COUNT(DISTINCT e.application_instance_id) AS instituciones
FROM event e
JOIN event_type et ON et.id = e.type_id
WHERE e.timestamp > NOW() - INTERVAL '12 months'
GROUP BY 1, 2 ORDER BY 1 DESC, 3 DESC;
-- RESULTADO: [COMPLETAR - tabla con tendencia de launches y otros eventos]

-- 9. Calificaciones sincronizadas
SELECT
    COUNT(*) AS total_grades,
    COUNT(*) FILTER (WHERE success = true) AS exitosas,
    ROUND(AVG(grade) FILTER (WHERE success = true), 3) AS promedio_grade
FROM grading_sync_grade;
-- Total: [COMPLETAR] | Exitosas: [COMPLETAR] | Promedio: [COMPLETAR]

-- 10. Proxy de salud por institución (top 20)
SELECT
    o.name AS institucion,
    ai.last_launched,
    COUNT(DISTINCT lc.id) AS cursos_activos,
    COUNT(DISTINCT lu.id) AS usuarios_unicos,
    CASE
        WHEN ai.last_launched > NOW() - INTERVAL '90 days' THEN 'Activo'
        WHEN ai.last_launched > NOW() - INTERVAL '180 days' THEN 'En riesgo'
        ELSE 'Inactivo'
    END AS estado_salud
FROM organization o
JOIN application_instances ai ON ai.organization_id = o.id
LEFT JOIN lms_course_application_instance lcai ON lcai.application_instance_id = ai.id
LEFT JOIN lms_course lc ON lc.id = lcai.lms_course_id
LEFT JOIN lms_user_application_instance luai ON luai.application_instance_id = ai.id
```

```
LEFT JOIN lms_user lu ON lu.id = luai.lms_user_id
GROUP BY 1, 2 ORDER BY cursos_activos DESC LIMIT 20;
-- RESULTADO: [COMPLETAR – tabla de las 20 instituciones más activas]
```

Data Maturity Assessment

Dominio	Nivel	Descripción
Data Collection	2 / 5	Datos operacionales sí. Eventos de comportamiento, no
Data Quality	2 / 5	Sin validaciones automatizadas ni procesos de limpieza formales
Data Governance	1 / 5	Sin ownership formal, sin catalog, sin glosario
Analytics	2 / 5	Algunas métricas LMS disponibles, sin capa analítica central
Product Analytics	1 / 5	Endpoint existe en código, no implementado
Self-Service Analytics	1 / 5	No existe. Todo análisis requiere acceso directo a BD
AI / ML Readiness	2 / 5	Datos existen pero no están curados ni centralizados

Score global: 1.6 / 5

Current Pain by Team

Este assessment existe porque cada área de la compañía enfrenta hoy limitaciones concretas por falta de datos. Estas son las fricciones que la estrategia de datos debe resolver.

Área	Pain hoy	Consecuencia
Product	No saben qué features generan engagement real. Las decisiones de roadmap se basan en intuición, no en datos de uso	Features se construyen sin validación cuantitativa. Inversión mal asignada
Customer Success	No pueden detectar señales de churn antes de que el cliente avise que no renueva	CS actúa reactivamente. Pérdida de cuentas que podrían haberse salvado
Sales	No pueden demostrar ROI en una reunión de renovación. No tienen datos de engagement por institución para conversaciones de upsell	Renovaciones se negocian sin evidencia. Tasa de cierre sub-óptima
Leadership	No tienen una visión unificada del negocio. Uso y revenue viven en sistemas separados. Las decisiones estratégicas se basan en datos parciales	Asignación de recursos sub-óptima. Incapacidad de proyectar crecimiento con precisión
Engineering	No existe ownership formal de analytics. El analytics service tiene un TODO en el código desde hace tiempo. Sin priorización clara	Deuda técnica creciente en datos. Nadie es responsable de que los datos estén disponibles
Finance	No pueden correlacionar niveles de uso con probabilidad de renovación	No pueden priorizar recursos en cuentas de alto riesgo vs alto valor

Quick Wins — Próximos 30 Días

Estas acciones son ejecutables de inmediato, tienen alta visibilidad y generan momentum organizacional.

Acción	Esfuerzo	Resultado inmediato	Impacto en negocio
Ejecutar queries de Volumetría Real	1 día	Primer baseline real: volúmenes, crecimiento, distribución	Diagnóstico deja de ser una hipótesis. Base para solicitar presupuesto
Dashboard proxy desde datos existentes	1-2 semanas	Health Score básico por institución desde <code>lms.event</code> + <code>lms.application_instances</code>	CS tiene visibilidad desde el mes 1, sin esperar el DW ni el tracking
Diseño del sistema de eventos	1 semana	Taxonomía de eventos + arquitectura de write-path definida	Evita reescribir el sistema después de construirlo mal
Resource tracking en client	2-3 días	Saber qué tipo de recurso genera más anotaciones	Product puede priorizar inversión por tipo de contenido
Ejecutar queries de calidad de datos	1-2 días	Primer baseline de calidad de datos	Identifica riesgos antes de construir el DW
Entrevistas a CS/Sales/Finance	1 semana	Revenue model confirmado, KPIs validados	Completa el Bloque 0 y Revenue Assessment

Nota sobre el analytics endpoint: No está en los Quick Wins de 30 días porque no es un cambio de 2-3 días — ver análisis técnico en Bloque 4, sección 4.4.

Bloque 0 — Entendimiento del Negocio

0.1 Business Model Canvas

Dimensión	Descripción
Clientes	Universidades, colleges e instituciones educativas de nivel superior
Usuarios finales	Estudiantes (anotan, responden, colaboran) y profesores (configuran, revisan, califican)
Compradores	CIO, Academic Technology Officers, LMS Administrators, Decanos
Propuesta de valor	Anotación colaborativa sobre cualquier material educativo. Fomenta lectura activa, participación y aprendizaje profundo. Se integra sin fricción con el LMS existente de la institución
Canales	Integración LTI con LMS (Canvas, Blackboard, D2L, Moodle) + web directo
Relación con clientes	Contrato institucional anual, onboarding, soporte técnico, Customer Success dedicado
Fuentes de ingreso	[REQUIERE ENTREVISTA] — presumiblemente licencias por cantidad de estudiantes activos o por institución
Recursos clave	Plataforma de anotación (h), integración LMS (lms), cliente JS (client), equipo CS
Actividades clave	Mantener integraciones LMS, onboarding institucional, soporte, desarrollo de producto
Socios clave	Proveedores LMS (Instructure, Anthology, D2L, Moodle), proveedores contenido (JSTOR, VitalSource)
Estructura de costos	Infraestructura AWS, ingeniería, Customer Success, integraciones de contenido

0.2 Revenue Drivers

Driver	Fuente de datos	Disponibilidad
Universidades activas	<code>organization</code> + <code>application_instances</code> (lms)	✓ BD lms
Estudiantes activos	<code>lms_user</code> + <code>lms_course_membership</code> (lms)	✓ BD lms
Cursos con Hypothesis	<code>lms_course</code> (lms)	✓ BD lms
Licencias contratadas	—	✗ HubSpot / billing externo
Contratos y renovaciones	—	✗ HubSpot / billing externo
Churn proxy	<code>application_instances.last_launched</code>	⚠ Aproximado

0.3 North Star Metrics propuestas


Métrica	Descripción	Fuente disponible
Monthly Active Students (MAS)	Estudiantes únicos con al menos 1 anotación o launch en el mes	<code>annotation</code> (h) + <code>event</code> (lms)
Monthly Active Instructors (MAI)	Instructores únicos que configuran o revisan asignaciones	<code>event_user</code> con rol instructor (lms)
Annotation Rate	Anotaciones promedio por estudiante por curso	<code>annotation</code> (h) + <code>lms_course_membership</code> (lms)
Launch → Annotation Conversion	% de launches que resultan en al menos 1 anotación	<code>event</code> (lms) + <code>annotation</code> (h)
Retención semestral	% de cursos/instituciones que continúan el siguiente semestre	<code>lms_course</code> + <code>lms_term</code> (lms)
Renewal Rate	% de contratos renovados	✗ HubSpot / billing externo

0.4 KPIs por área


Área	KPI	Calculable hoy
Product	MAU / DAU	⚠️ Parcial
	Retención 30/60/90 días	⚠️ Parcial
	Annotation Rate por curso	✅ Sí
	Feature adoption rate	❌ No
Customer Success	Health Score por institución	⚠️ Proxy solamente
	Adoption Score (cursos activos / contratados)	❌ Falta dato contratos
	Churn Risk Score	⚠️ Proxy desde last_launched
Sales	ARR	❌ No en BDs
	Renewal Rate	❌ No en BDs
	Expansion Revenue (nuevos cursos en clientes existentes)	⚠️ Parcial
Engineering	Availability	❌ New Relic
	Error Rate	❌ Sentry
	Response Time	❌ New Relic
Education	Annotation Density por recurso	✅ Sí
	Student Participation Rate en un curso	✅ Sí
	Collaboration Index (replies / anotaciones)	✅ Sí

0.5 Customer Journey

Journey del Instructor



Journey del Estudiante



Cobertura del journey

Paso	Medible hoy	Cómo
Launch desde LMS	✓	<code>event.configured_launch</code> (lms)
Configura asignación	✓	<code>event.deep_linking</code> / <code>edited_assignment</code> (lms)
Abre recurso	✗	No implementado
Lee contenido	✗	No implementado
Crea anotación	⚠ Parcial	<code>annotation</code> table — no hay evento explícito
Responde	⚠ Parcial	<code>annotation.references</code> — inferido
Menciona usuario	✓	<code>mention</code> table (h)
Calificación enviada	✓	<code>grading_sync_grade</code> (lms)

Los pasos de mayor valor educativo (apertura de recurso, lectura) son los menos medibles. Esto hace imposible hoy demostrar cuánto "usa" un estudiante Hypothesis.

0.6 Preguntas del Board

- ¿Qué universidades usan más el producto? ¿Cuántos cursos activos tiene cada una?
- ¿Qué LMS tiene mayor tasa de adopción?
- ¿Cuántos estudiantes usan activamente Hypothesis este semestre?
- ¿Qué recursos generan más anotaciones?
- ¿Qué instituciones están en riesgo de churn?
- ¿Cuánto revenue está asociado a cada nivel de uso?
- ¿Qué instituciones tienen contratos próximos a vencer?

Bloque 1 — Arquitectura

1.1 Repositorios

Repositorio	Función	Tecnología	Base de datos
hypothesis/h	Backend central: API REST, autenticación, grupos, búsqueda, admin	Python 3.11 + Pyramid, Celery, Gunicorn	PostgreSQL + Elasticsearch
hypothesis/lms	Integración LTI con LMS educativos	Python 3.11 + Pyramid, Celery, Gunicorn	PostgreSQL separada
hypothesis/client	Cliente JS inyectable en páginas web	TypeScript + Preact + Redux, Rollup	Sin BD propia

1.2 Infraestructura

```

AWS (us-west-1 + ca-central-1)

ElasticBeanstalk: h (web) + h-websocket
ElasticBeanstalk: lms (web + Celery workers)

RDS PostgreSQL: BD h —FDW— RDS PostgreSQL: BD lms
Elasticsearch 7.10 (índice annotations)
RabbitMQ 3.12 (colas: celery, annotation, email_digests)
S3 (assets) · CloudFront (CDN) · Route53 (DNS)

```

1.3 Integraciones Externas

Sistema	Tipo	Riesgo
Canvas, Blackboard, D2L, Moodle	LMS (bidireccional)	● Crítico — ver R9
JSTOR, VitalSource, YouTube	Contenido (entrada)	● Medio
HubSpot	CRM (salida, Celery diaria)	● Medio — contiene datos de revenue
Sentry, New Relic	Observabilidad (salida)	● Bajo
Google Analytics	Analytics (salida)	● Bajo — uso no confirmado

1.4 Flujo de datos



Revenue Data Assessment

Hallazgo: Los datos de monetización no están en las bases de datos de la aplicación. Uso y dinero viven en sistemas separados — hoy no es posible correlacionar nivel de adopción con riesgo de churn o probabilidad de renovación.

Dato	Encontrado	Ubicación probable
Clientes / Universidades	✓ Parcial	organization + application_instances
Estudiantes activos	✓	lms_user (lms)
Contratos y renovaciones	✗	HubSpot
Licencias y pricing	✗	HubSpot / billing externo
Facturación	✗	Billing externo
Churn real	✗	Proxy: application_instances.last_launched

Proxy de salud por institución (ejecutar query 10 de Volumetría Real).

Acciones recomendadas: Acceso a HubSpot + entrevistas con Finance/CS/Sales.

Mapa de Ownership de Datos

Dominio	Dueño funcional	Sistema	Estado governance
Annotations	Product / Backend	h	Sin governance formal
Users & Auth	Platform / Backend	h	Sin governance formal
LMS Integration	LMS/EdTech Team	lms	Sin governance formal
Courses & Assignments	LMS/EdTech Team	lms	Sin governance formal
Grading	LMS/EdTech Team	lms	Sin governance formal
Organizations / Billing	Finance / Sales	HubSpot + externo	Desconectado de uso
CRM / Contracts	Sales	HubSpot	Desconectado de uso
Analytics	Data Engineering	⚠ No existe aún	Por crear

Sin un dueño transversal de datos, cada equipo define sus propias métricas. "Usuario activo" puede significar cosas distintas para Product, CS y Finance.

Evaluación de Riesgos

#	Riesgo	Severidad	Impacto en negocio	Acción
R1	Analytics service no implementado (<code>TOD0</code> en código)	● Crítico	Pérdida permanente de información de engagement. Implementación correcta = 3-6 semanas, no días (ver 4.4)	Diseño de sistema de eventos en Sprint 1. Implementación en Fase 1
R2	Sin tracking de sesiones ni tiempo de uso	● Alto	No se puede demostrar valor a universidades	Session tracking en client — parte del sistema de eventos
R3	Eventos de anotación no persistidos en h	● Alto	Sin fuente de verdad para actividad histórica	Tabla <code>annotation_event</code> en h como parte de Fase 1
R4	LTI params purgados a 30 días	● Crítico	Destruye la capacidad de Learning Analytics histórico y reportes YoY — ver análisis completo abajo	S3 cold archive inmediato antes de la próxima ejecución del purge
R5	Datos de revenue fuera del sistema	● Medio	No se puede correlacionar uso con ingresos	Pipeline HubSpot → DW
R6	Dependencia de joins h ↔ lms via <code>h_userid</code>	● Medio	Complejidad analítica. Un error rompe todos los análisis	Validar integridad (ejecutar queries de Sección 3.4)
R7	Elasticsearch 7.10 en EOL	● Medio	Riesgo de seguridad a mediano plazo	Planificar upgrade
R8	Sin tipo de recurso normalizado	● Bajo	No se puede segmentar uso por tipo de material	Campo <code>resource_type</code> en <code>assignment</code>
R9	Dependencia crítica de LMS externos	● Alto	Si cualquier LMS cambia su API: launches fallan, sync falla, calificaciones fallan	Monitoreo activo de changelogs LMS. Versionado de integraciones. Alertas tempranas

R4 — Análisis detallado: LTI params purgados a 30 días

Qué hace el código realmente (`lms/lms/tasks/event.py`):

```
@app.task
def purge_launch_data(*, max_age_days=30) → None:
    # Elimina el key 'lti_params' del JSONB en EventData.data
    # Solo opera en eventos de 30 a 60 días de antigüedad
    # NO borra la fila del evento – solo el campo lti_params del JSON
    update(EventData).values(data=EventData.data - "lti_params")
```

Lo que sobrevive a la purga:

- La fila completa en `event` (timestamp, type, application_instance_id, course_id, assignment_id, grouping_id)
- `event_user` (usuario + rol al momento del evento)

Lo que se pierde permanentemente después de 30 días:

| Campo perdido | Por qué importa para analytics |

|-----|-----|

| `context_title` (nombre del curso) | Si el curso fue renombrado, el nombre histórico se pierde — los reportes YoY no pueden mostrar "Introducción a la Biología 2024 vs 2025" |

| `lis_person_contact_email_primary` | Email del usuario al momento del launch. Crucial para identidad histórica si cambió su email |

| Campos de término académico (`custom_*`) | Canvas y otros LMS envían término, semestre, cohorte como custom params — no están en columnas estructurales |

| `tool_consumer_instance_guid` | Identificador de la instancia LMS al momento del evento |

| Parámetros custom del LMS | Cada institución puede enviar datos propios (código de departamento, nivel del curso, modalidad) |

Por qué es Crítico y no Medio:

Los reportes semestrales y YoY que los compradores universitarios usan para justificar renovaciones requieren contexto histórico. Con la purga a 30 días, cualquier reporte sobre "Semester Spring 2024 vs Spring 2025" pierde el contexto del término académico si ese dato vivía en `lti_params` y no en una columna estructural.

Solución de ingeniería inmediata (prioridad antes del próximo ciclo de purge):

```
# Modificar purge_launch_data() para archivar ANTES de eliminar
import boto3, json

@app.task
def purge_launch_data(*, max_age_days=30) → None:
    s3 = boto3.client('s3')
    events_to_purge = ... # query existente

    # 1. Archivar a S3 cold storage (Glacier Instant Retrieval ~$0.004/GB/mes)
    archive_data = [
        {"event_id": row.event_id, "lti_params": row.data["lti_params"]}
        for row in events_to_purge if "lti_params" in row.data
    ]
    s3.put_object(
        Bucket='hypothesis-lti-archive',
        Key=f'lti_params/{datetime.utcnow().strftime("%Y/%m/%d")}.json.gz',
        Body=gzip.compress(json.dumps(archive_data).encode())
    )

    # 2. Ejecutar purge original
    # ... código existente ...
```

Costo estimado del archivo: A \$0.004/GB/mes (Glacier), incluso con millones de eventos el costo es negligible. La retención histórica es invaluable.

Bloque 2 — Modelo de Datos

2.1 Entidades estratégicas del negocio

Entidad	Tabla(s) fuente	Sistema	Descripción
Institution	organization , application_instances	lms	Universidad cliente. Unidad de contrato y revenue
Student	lms_user (rol learner), user (h)	lms + h	Usuario que anota y colabora
Instructor	lms_user (rol instructor), user (h)	lms + h	Usuario que configura y evalúa
Course	lms_course , grouping	lms	Contexto educativo del uso
Assignment	assignment	lms	Tarea que involucra anotar un recurso
Resource	assignment.document_url , file , document	lms + h	Material educativo (PDF, video, HTML, libro)
Annotation	annotation	h	Acción central del producto — el valor entregado
Session	✗ No existe	—	Período de uso continuo. Debe construirse

2.2 Inventario de tablas — BD **h** (31 tablas)

Tabla	Descripción	PK	FKs principales
user	Usuarios con perfil, estado, flags (admin, staff, nipsa, deleted)	id	activation_id
user_identity	Identidades externas (ORCID, Google, Facebook)	id	user_id
activation	Tokens de activación	id	—
authclient	Cientes OAuth 2.0	id (UUID)	—
authzcode	Códigos de autorización OAuth	id	user_id , authclient_id
authticket	Tickets de sesión web	id	user_id
token	API tokens de acceso y refresh	id	user_id , authclient_id
group	Grupos de anotación	id	creator_id → user , organization_id
user_group	Membresía usuario-grupo con roles JSONB	id	user_id , group_id
groupscope	Alcance de URLs del grupo	id	group_id
organization	Organizaciones	id	—
annotation	Tabla central. Texto, tags, selectores, moderación	id (UUID)	document_id
annotation_slim	Vista desnormalizada para queries rápidas	id	pubid → annotation , user_id , group_id , document_id
annotation_metadata	Metadata extendida JSONB	annotation_id	annotation_id → annotation_slim
document	Documento web anotado	id	—
document_uri	URLs concretas del documento	id	document_id
document_meta	Metadata (título, autor)	id	document_id
mention	Menciones @usuario	id	annotation_id , user_id
notification	Notificaciones (reply, mention)	id	source_annotation_id , recipient_id
flag	Reportes de anotaciones	id	annotation_id , user_id
moderation_log	Log de cambios de moderación	id	annotation_id , moderator_id

Tabla	Descripción	PK	FKs principales
subscriptions	Preferencias de notificación	id	—
feature	Feature flags	id	—
featurecohort	Grupos para A/B testing	id	—
featurecohort_user	Relación usuario-cohorte	id	user_id , cohort_id
featurecohort_feature	Relación cohorte-feature	id	feature_id , cohort_id
job	Cola de jobs internos	id	—
task_done	Registro de tareas completadas	id	—
user_deletion	Auditoría de borrado de usuarios	id	—
blocklist	URLs bloqueadas	id	—
setting	Key-value settings del sistema	key	—

2.3 Inventario de tablas — BD `lms` (30 tablas)

Tabla	Descripción	PK	FKs principales
<code>organization</code>	Universidad / institución cliente	<code>id</code>	<code>parent_id</code> → <code>organization</code>
<code>application_instances</code>	Instalación de Hypothesis en un LMS	<code>id</code>	<code>organization_id</code> , <code>lti_registration_id</code>
<code>lti_registration</code>	Registro LTI 1.3	<code>id</code>	—
<code>lms_user</code>	Usuario canónico con <code>h_userid</code> para vincular con h	<code>id</code>	—
<code>user</code>	Usuario en contexto de instancia específica	<code>id</code>	<code>application_instance_id</code>
<code>lms_user_application_instance</code>	Relación usuarios-instancias	<code>id</code>	<code>lms_user_id</code> , <code>application_instance_id</code>
<code>lms_term</code>	Período académico con fechas	<code>id</code>	—
<code>lms_course</code>	Curso en el LMS	<code>id</code>	<code>lms_term_id</code>
<code>lms_course_application_instance</code>	Relación curso-instancia	<code>id</code>	<code>lms_course_id</code> , <code>application_instance_id</code>
<code>lms_course_membership</code>	Membresía usuarios-cursos con rol LTI	<code>id</code>	<code>lms_course_id</code> , <code>lms_user_id</code> , <code>lti_role_id</code>
<code>lti_role</code>	Roles LTI (instructor, learner, admin)	<code>id</code>	—
<code>lti_role_override</code>	Override de roles por instancia	<code>id</code>	<code>lti_role_id</code> , <code>application_instance_id</code>
<code>grouping</code>	Entidad polimórfica: curso, sección, grupo	<code>id</code>	<code>application_instance_id</code> , <code>parent_id</code> → <code>grouping</code>
<code>grouping_membership</code>	Membresía usuarios-groupings	<code>(grouping_id, user_id)</code>	ambas FKs

Tabla	Descripción	PK	FKs principales
group_info	Información legacy de grupos LMS	id	application_instance_id
assignment	Asignación con URL del documento a anotar	id	course_id → grouping , auto_grading_config_id
assignment_auto_grading_config	Configuración de auto-calificación	id	—
assignment_grouping	Relación asignaciones-groupings	(assignment_id, grouping_id)	ambas FKs
file	Archivo del LMS en una asignación	id	application_instance_id
grading_sync	Proceso de sincronización de calificaciones	id	assignment_id , created_by_id → lms_user
grading_sync_grade	Calificación individual de estudiante	id	grading_sync_id , lms_user_id
lis_result_sourcedid	Info de calificación LTI 1.1 (legacy)	id	application_instance_id
oauth2_token	Tokens OAuth2 para APIs LMS	id	application_instance_id
jwt_oauth2_token	Tokens JWT para LTI 1.3	id	lti_registration_id
rsa_key	Claves RSA para firma JWT	id	—
event	Tabla de eventos LMS	id	type_id , application_instance_id , course_id , assignment_id
event_type	Catálogo de tipos de evento	id	—
event_user	Usuarios en un evento con su rol	id	event_id , user_id , lti_role_id
event_data	Datos extra del evento en JSONB	event_id	event_id → event

Tabla	Descripción	PK	FKs principales
notification	Notificaciones reply/mention en contexto LMS	id	sender_id, recipient_id → lms_user, assignment_id

2.4 Relaciones entre BDs

```
lms.lms_user.h_userid ↔ h.user.userid (formato: acct:username@authority)
lms.grouping.authority_provided_id ↔ h.group.authority_provided_id
```

La BD `lms` puede leer la BD `h` via **Foreign Data Wrapper (FDW)**.

Bloque 3 — Calidad de Datos

Ejecutar en producción. Resultados a completar en Volumetría Real.

3.1 Completitud

```
-- Usuarios sin email (BD h)
SELECT COUNT(*), COUNT(*) FILTER (WHERE email IS NULL) AS sin_email
FROM "user" WHERE deleted = false;

-- Anotaciones sin target_uri
SELECT COUNT(*) FROM annotation WHERE target_uri IS NULL OR target_uri = '';

-- Usuarios LMS sin h_userid (BD lms)
SELECT COUNT(*) FROM lms_user WHERE h_userid IS NULL;

-- Eventos sin usuario (BD lms)
SELECT COUNT(*) FROM event e
LEFT JOIN event_user eu ON eu.event_id = e.id WHERE eu.user_id IS NULL;
```

3.2 Duplicados

```
-- Emails duplicados por authority (BD h)
SELECT email, authority, COUNT(*) AS n FROM "user"
WHERE email IS NOT NULL AND deleted = false
GROUP BY email, authority HAVING COUNT(*) > 1 ORDER BY n DESC LIMIT 20;

-- h_userid duplicados (BD lms)
SELECT h_userid, COUNT(*) FROM lms_user GROUP BY 1 HAVING COUNT(*) > 1;
```

3.3 Consistencia

```
SELECT COUNT(*) FROM annotation WHERE updated < created; -- Fechas invertidas (BD h)
SELECT COUNT(*) FROM grading_sync_grade WHERE grade < 0 OR grade > 1; -- Notas inválidas (BD lms)
SELECT COUNT(*) FROM lms_course WHERE ends_at < starts_at; -- Fechas de curso inválidas (BD lms)
```

3.4 Integridad Referencial

```
-- annotation_slim sin annotation padre (BD h)
SELECT COUNT(*) FROM annotation_slim asm
WHERE NOT EXISTS (SELECT 1 FROM annotation a WHERE a.id = asm.pubid);

-- Eventos con application_instance inexistente (BD lms)
SELECT COUNT(*) FROM event e
WHERE application_instance_id IS NOT NULL
AND NOT EXISTS (SELECT 1 FROM application_instances ai WHERE ai.id =
e.application_instance_id);
```

Bloque 4 — Assessment de Tracking

4.1 Eventos existentes

BD **lms** — Persistidos

Evento	Descripción
configured_launch	Usuario abre Hypothesis desde el LMS
deep_linking	Profesor configura asignación nueva
edited_assignment	Profesor edita asignación existente
submission	Estudiante envía trabajo
grade	Sistema sincroniza calificación
audit	Cambios en modelos (audit trail)
error_code	Error durante acción LTI

LTI params purgados a 30 días automáticamente — contexto histórico perdido (ver R4 Crítico).

BD **h** — En memoria, no persistentes

Evento	Traza disponible
AnnotationEvent (create/update/delete)	Solo tabla <code>annotation</code>
ModeratedAnnotationEvent	Solo <code>moderation_log</code>
LoginEvent / LogoutEvent / ActivationEvent	Solo logs, no persistentes

4.2 Cobertura

Acción	Trackeado	Dónde
Abrir desde LMS	✓	<code>event.configured_launch</code>
Crear anotación	⚠	Solo tabla <code>annotation</code>
Responder	⚠	<code>annotation.references</code> (inferido)
Mencionar	✓	<code>mention</code> (h)
Calificación	✓	<code>grading_sync_grade</code> (lms)
Abrir recurso (PDF/video)	✗	—
Tiempo de uso	✗	—
Búsqueda	✗	—
Sesión	✗	—

4.3 Frecuencia

```
-- Eventos por tipo y mes (BD lms)
SELECT DATE_TRUNC('month', e.timestamp) AS mes, et.type, COUNT(*),
       COUNT(DISTINCT e.application_instance_id) AS instituciones
FROM event e JOIN event_type et ON et.id = e.type_id
GROUP BY 1, 2 ORDER BY 1 DESC, 3 DESC;

-- Anotaciones por mes (BD h)
SELECT DATE_TRUNC('month', created) AS mes, COUNT(*),
       COUNT(DISTINCT userid) AS usuarios,
       COUNT(*) FILTER (WHERE array_length(references, 1) > 0) AS replies
FROM annotation WHERE deleted = false GROUP BY 1 ORDER BY 1 DESC LIMIT 24;
```

4.4 Análisis técnico: por qué el analytics endpoint lleva años como TODO

Lo que el código hace hoy (`h/h/services/analytics.py`):

```
class AnalyticsService:
    def create(self, event: Event):
        # TODO Enhance this
        self._log.info(event) # ← es literalmente un logger. No hay BD, no hay tabla.
```

El endpoint existe (`POST /api/v1/analytics/events`), el schema valida exactamente 1 tipo de evento (`client.realtime.apply_updates` — disparado cuando un usuario hace clic en "aplicar actualizaciones" del panel de notificaciones en tiempo real). El cliente lo envía correctamente. El backend simplemente lo descarta al log.

Por qué no se implementó en los sprints anteriores:

No fue un olvido. La implementación correcta es un problema de sistemas distribuidos, no de "agregar una tabla":

Problema	Detalle
Write amplification	Canvas tiene decenas de miles de estudiantes simultáneos. Cada uno genera múltiples eventos por sesión. Si cada evento es un POST síncrono → write en el mismo PostgreSQL OLTP que sirve annotations, auth y API: contención garantizada bajo carga
Schema demasiado estrecho	Solo acepta 1 evento (<code>apply_updates</code>). Para Learning Analytics útil necesitas 10-20 tipos: <code>annotation_created</code> , <code>resource_opened</code> , <code>session_started</code> , <code>session_ended</code> , <code>search_performed</code> , <code>highlight_created</code> , etc. Requiere rediseño completo
Auth overhead por evento	Cada POST pasa por el stack completo de Pyramid (JWT decode, session validation, routing). Para eventos de alta frecuencia, esto agrega latencia innecesaria en cada request
Sin batching	El client envía un POST por evento. A escala, esto significa miles de requests/minuto adicionales al API
RabbitMQ no es la solución	RabbitMQ está configurado para Celery task queues. No está diseñado ni dimensionado para streaming de eventos de comportamiento a esta escala

Arquitectura correcta para implementarlo (3-6 semanas, 1 Data + 1 Backend Engineer):

```
CLIENT (batching local cada 30s)
  ↓ POST /api/analytics/events (payload: batch de eventos)
H API (validación ligera de JWT, sin sesión completa)
  ↓ publicar a SQS (desacoplamiento, no bloquea la API)
AWS Lambda consumer (o Celery worker dedicado)
  ↓ escribir a tabla analytics_event SEPARADA del OLTP
  ↳ (opcional) exportar a S3 Parquet para Athena
```

Taxonomía de eventos prioritarios a capturar:

Evento	Prioridad	Métricas que habilita
<code>session.started</code>	● Alta	Tiempo de uso, DAU real
<code>session.ended</code> (con duración)	● Alta	Tiempo promedio por sesión, engagement real
<code>resource.opened</code> (type: pdf/video/html)	● Alta	Apertura de recurso, embudo launch→apertura
<code>annotation.created</code>	● Alta	Evento explícito (hoy solo inferido de tabla)
<code>annotation.reply_created</code>	● Alta	Collaboration Index real
<code>resource.scrolled</code> (% leído)	● Media	Reading depth, proxy de lectura activa
<code>search.performed</code>	● Media	Discovery patterns
<code>annotation.highlight_created</code>	● Media	Engagement sin anotación escrita


Estimación realista:

- **Mal implementado (directo a PostgreSQL OLTP):** 3 días, funcionará en dev, fallará en producción bajo carga real.
- **Bien implementado (SQS buffer + tabla dedicada + client batching):** 3-6 semanas. Esta es la única versión que vale la pena construir.

Bloque 5 — Modelo Analítico Futuro

5.1 Arquitectura target — AWS-native

La propuesta de infraestructura analítica está diseñada para el stack AWS que ya existe en producción. No se introducen herramientas externas hasta que la carga lo justifique.



Orquestación: Amazon EventBridge Scheduler para jobs simples (diarios/semanales). AWS Step Functions para pipelines con dependencias. Amazon MWAA (managed Airflow) solo si la complejidad lo justifica en Fase 3.

5.2 Justificación del stack AWS-native

Herramienta rechazada	Por qué no	Alternativa AWS
Airbyte	Overhead de mantenimiento (servidor propio o cloud \$\$\$). Justifica solo a escala alta. Sin beneficio vs DMS para RDS→S3	AWS DMS (CDC) + AWS Glue (batch ETL) — ya gestionados, en el mismo VPC
BigQuery	Multi-cloud. Datos salen de AWS a GCP. Latencia de red, costos de egress, dos proveedores cloud que gestionar	Amazon Athena sobre S3: serverless, mismo región, pago por query ejecutada
Redshift (provisioned)	Costo fijo ~\$180-250/mes mínimo. Sobre-dimensionado para empezar	Athena primero (pay-per-query). Redshift Serverless solo si queries > 10TB/mes frecuentes
Airflow/Dagster (self-hosted)	Servidor adicional, mantenimiento. Innecesario para pipelines simples	EventBridge Scheduler (cron jobs) + Step Functions (pipelines con estados)
Looker	Licencia enterprise \$\$\$\$. Injustificable en Fase 2	Amazon QuickSight (embedded) o Metabase (self-hosted, open source)

Costo estimado del stack AWS-native:

| Componente | Costo estimado/mes |

|-----|-----|

| AWS DMS (t3.micro) | ~\$15 |

| S3 (100GB Parquet) | ~\$2.50 |

| AWS Glue (10 DPU-horas/día) | ~\$13 |

| Amazon Athena (100GB queries/mes) | ~\$5 |

| Metabase (EC2 t3.small self-hosted) | ~\$15 |

| **Total Fase 2** | **~\$50/mes** |

vs. Airbyte Cloud (~\$200+) + BigQuery (~\$100+ según uso) + Looker (\$\$\$).

5.3 Esquema estrella

Tabla	Tipo	Fuente	Factibilidad
DimDate	Dimensión	Generada	✓ Hoy
DimInstitution	Dimensión	organization + application_instances	✓ Hoy
DimUser	Dimensión	lms_user + user (h)	✓ Hoy
DimCourse	Dimensión	lms_course + lms_term	✓ Hoy
DimAssignment	Dimensión	assignment	✓ Hoy
DimResource	Dimensión	file + document	✓ Hoy
FactAnnotations	Hecho	annotation (h)	✓ Hoy
FactEvents	Hecho	event + event_user (lms)	✓ Hoy
FactGrades	Hecho	grading_sync_grade (lms)	✓ Hoy
FactSessions	Hecho	—	✗ Requiere sistema de eventos (Fase 1)

Bloque 6 — Roadmap

Principio guía: Tracking → Data Layer → Data as a Product. **Las Fases 1 y 2 se solapan desde el mes 2.** CS no puede esperar 18 meses — necesita un proxy de churn funcional en el mes 2, no en el mes 18.

Fase 1 — Tracking Foundation (meses 1-3)

Objetivo: Capturar los datos que hoy se pierden. Sin estos datos, el DW organizará información incompleta.
Equipo: 1 Data Engineer + 1 Frontend Engineer (part-time).
Costo estimado: 2-3 meses de trabajo. Infraestructura: ~\$30/mes adicional (SQS + tabla analytics).

Iniciativa	Prioridad	Semanas	Impacto en revenue	Outcome esperado
S3 cold archive de LTI params	● Inmediata (antes del próximo purge)	0.5	Preserva datos históricos ya existentes	Reportes YoY posibles. Sin esto, datos históricos irrecuperables
Diseño del sistema de eventos	● Alta	1	Fundacional	Taxonomía de eventos + arquitectura definida. Evita reescribir
Analytics endpoint (write-path correcto)	● Alta	4-6	Base de todo analytics futuro	SQS buffer + tabla <code>analytics_event</code> dedicada + client batching
Session tracking	● Alta	2	Tiempo de uso → mejora argumentos de renovación	Primera métrica de engagement real
Resource tracking (PDF/video/HTML)	● Alta	1	Segmentación por tipo de contenido	Product prioriza inversión por tipo
Annotation events explícitos	● Media	1	Actividad histórica reconstruible	Fuente de verdad para analytics de anotaciones

Inicio Fase 2: Mes 2 (paralela con Fase 1)

El primer dashboard de CS no requiere el DW ni el tracking completo. Los datos en `lms.event` + `lms.application_instances` + `h.annotation` ya son suficientes para un proxy de salud básico.

CS Churn MVP — Meta: operativo en el mes 2:

```
-- Dashboard proxy de salud (ejecutable hoy, sin DW)
-- Implementar como vista en Metabase conectado a RDS read replica
SELECT
    o.name AS institucion,
    ai.last_launched,
    COUNT(DISTINCT e.id) FILTER (
        WHERE e.timestamp > NOW() - INTERVAL '90 days'
        AND et.type = 'configured_launch'
    ) AS launches_90d,
    COUNT(DISTINCT eu.user_id) AS usuarios_unicos_90d,
    CASE
        WHEN ai.last_launched > NOW() - INTERVAL '30 days' THEN '🟢 Saludable'
        WHEN ai.last_launched > NOW() - INTERVAL '90 days' THEN '🟡 Atención'
        ELSE '🔴 Riesgo de churn'
    END AS estado
FROM organization o
JOIN application_instances ai ON ai.organization_id = o.id
LEFT JOIN event e ON e.application_instance_id = ai.id
LEFT JOIN event_type et ON et.id = e.type_id
LEFT JOIN event_user eu ON eu.event_id = e.id
GROUP BY 1, 2 ORDER BY launches_90d DESC;
```

Fase 2 — Data Layer MVP (meses 2-5)

Objetivo: Centralizar y gobernar los datos. Usar el stack AWS que ya existe.

Equipo: 2 Data Engineers.

Costo estimado: 3-4 meses de trabajo. Infraestructura: ~\$50/mes (ver tabla Sección 5.2).

Iniciativa	Semanas	Impacto en revenue	Outcome esperado
AWS DMS replication de RDS → S3	2	Habilita toda la capa analítica	Réplica continua a bajo costo sin tocar OLTP
Data Lake S3 + Glue Data Catalog	1	Fundacional para queries	Schema versionado, particionado por fecha
dbt models (staging + business layer)	3	Datos confiables y actualizados	Modelo estrella operativo con datos frescos diarios
Pipeline HubSpot → S3	2	Revenue + uso en un solo lugar	CS puede ver churn risk + valor contractual juntos
Metabase sobre Athena	1	CS + Sales tienen visibilidad	Primer BI funcional sin licencias enterprise
KPIs gobernados + glosario	1	Alineación organizacional	"Usuario activo" tiene una sola definición en toda la compañía

Fase 3 — Analytics as a Product (meses 5-12)

Objetivo: Reducir churn, mejorar renovaciones, demostrar ROI educativo, incrementar adopción orgánica.

Equipo: Squad dedicada (2 DE + 1 Data Analyst + 1 PM).

Costo estimado: 6-8 meses.

Iniciativa	Impacto en revenue	Outcome de negocio
Dashboard institucional (para clientes)	● Arma la conversación de renovación	El comprador ve ROI antes de la reunión de renovación. Tasa de renovación mejora
Health Score automatizado + alertas CS	● Detección temprana de churn	CS prioriza proactivamente. Cada cliente salvado = ARR preservado
Dashboard de curso para instructores	● Stickiness del producto	Instructores ven engagement de sus alumnos → NPS sube → menos churn orgánico
Predicción de churn (modelo ML)	● Retención proactiva	Identificar en riesgo 60-90 días antes de decisión. Intervención temprana
Benchmarking institucional	● Argumento de upsell	"Tu universidad genera 23% más anotaciones que instituciones similares"
Learning Analytics metrics	● Diferenciación competitiva	Annotation Density, Collaboration Index, At-Risk Index como oferta premium
Self-Service Analytics	● Autonomía interna	Equipos responden sus propias preguntas sin depender de DE

Timeline consolidado

Mes 1:	[F1] S3 archive LTI params · Diseño sistema eventos · Resource tracking
Mes 2:	[F1] Analytics endpoint (diseño + inicio impl.) · [F2-INICIO] CS Dashboard MVP
Mes 3:	[F1] Analytics endpoint (finalización) · Session tracking · [F2] DMS + Data Lake
Mes 4:	[F2] dbt models · Pipeline HubSpot · Metabase operativo ★ CS TIENE DASHBOARD DE CHURN REAL (no proxy) EN MES 4
Mes 5:	[F2] KPIs gobernados · [F3-INICIO] Dashboard institucional
Mes 6-8:	[F3] Health Score · Alertas CS · Dashboard instructores
Mes 9-12:	[F3] Predicción churn · Learning Analytics · Self-Service

Total: 12 meses (vs 24 meses en versión anterior)

Compliance & Privacy

En EdTech, privacidad no es opcional. Es un requisito de venta para universidades enterprise.

Dado que Hypothesis procesa datos educativos y comportamiento de estudiantes, cualquier estrategia analítica debe considerar:

Regulación / Estándar	Aplicabilidad	Implicación para analytics
FERPA (Family Educational Rights and Privacy Act)	● Alta — universidades USA	Datos de estudiantes son confidenciales. Analytics debe estar anonimizado o con consentimiento institucional
GDPR	● Media — universidades EU	Requiere base legal para procesamiento de datos de comportamiento. Derecho al olvido impacta pipelines
COPPA	● Potencial	Si hay usuarios menores de 13 años (edge case en educación superior)
Minimización de datos	● Best practice	Capturar solo lo necesario. No trackear más de lo que se va a usar
Retención de datos	● Media	Definir políticas de retención para eventos analíticos. ¿Cuánto tiempo se guarda una sesión?
Anonimización	● Alta	Los dashboards para clientes deben mostrar métricas agregadas, no datos individuales de estudiantes

Recomendación inmediata: Antes de implementar session tracking, definir con Legal qué datos pueden capturarse y por cuánto tiempo. Esto evita rediseñar el sistema después de construirlo.

Competitive Advantage Through Data — Learning Analytics

Esta es la oportunidad estratégica más importante del assessment.

La mayoría de los LMS tradicionales (Canvas, Blackboard, Moodle) tienen analytics débiles orientados a actividad de navegación: páginas visitadas, videos reproducidos, tiempo en plataforma. Estas métricas miden **presencia**, no **aprendizaje**.

Hypothesis tiene una oportunidad única y diferencial:

La anotación es interacción cognitiva. Cuando un estudiante anota un texto, está:

- Procesando activamente el contenido (no pasivamente)
- Produciendo evidencia de comprensión
- Colaborando intelectualmente con sus pares

Esto significa que los datos de Hypothesis no son analytics operacionales — son **Learning Analytics**: métricas de engagement intelectual que los LMS tradicionales no pueden medir.

Métricas de Learning Analytics posibles con los datos actuales:

Métrica	Descripción	Implicación pedagógica
Annotation Density	Anotaciones por página / por recurso	Indica profundidad de lectura
Collaboration Index	Replies / anotaciones totales	Mide diálogo académico entre pares
Cognitive Engagement Score	Longitud de anotaciones + menciones + replies	Proxy de procesamiento profundo
Knowledge Construction Rate	Nuevas anotaciones vs replies	Balance entre producción y diálogo
At-Risk Index	Estudiantes sin actividad en X días	Señal temprana de desenganche

Implicación comercial: Hypothesis puede posicionarse no como "herramienta de anotación" sino como **"plataforma de evidencia de aprendizaje activo"** — una categoría premium que justifica pricing más alto y diferencia claramente del commoditized LMS.

Este posicionamiento también facilita ventas a universidades con mandatos de accesibilidad, equity o evidencia de aprendizaje activo (creciente en educación superior).

Oportunidades de Producto Basadas en Datos

Para universidades (compradores)

- **Dashboard institucional:** actividad semestral, comparación YoY, evolución de adopción
- **Reporte de valor automático:** PDF generado en el momento de renovación con impacto del año
- **Benchmarking:** "Su universidad genera X% más anotaciones por estudiante que el promedio"

Para instructores (usuarios power)

- **Dashboard de curso:** participación por alumno, alumnos sin actividad, recursos más anotados
- **Alerta temprana:** "3 estudiantes no han abierto Hypothesis en 7 días"
- **Digest semanal automático:** resumen de actividad del curso

Para el equipo interno (CS/Sales)

- **Health Score por cliente:** adopción + engagement + tendencia
- **Churn Risk Score:** actividad reciente vs historial + fecha de renovación
- **Pipeline de expansión:** clientes que usan 1 LMS pero tienen más disponibles

Recomendación Organizacional

La estrategia de datos descrita en este documento no puede ejecutarse sin los cambios organizacionales correspondientes.

Para ejecutar la Fase 1: No se requieren cambios organizacionales. 1 Data Engineer con acceso a los repos y a la BD es suficiente.

Para ejecutar la Fase 2:

Necesidad	Descripción
Data Engineering function	Al menos 2 Data Engineers dedicados. No pueden ser borrowed time de producto
Data ownership formal	Cada dominio (Annotations, LMS, Revenue) necesita un dueño técnico responsable
Governance mínima	Glosario de términos compartido. ¿Qué es "usuario activo"? ¿Qué es "institución activa"?
Acceso unificado a datos	DE necesita acceso de lectura a BD h, BD lms y HubSpot
Budget herramientas	AWS DMS + S3 + Glue + Athena + Metabase: ~\$50/mes (ver desglose Sección 5.2)

Para ejecutar la Fase 3:

Necesidad	Descripción
Alineación Product + CS + Sales	Las 3 áreas deben acordar qué métricas son oficiales y cómo se calculan
Data PM o Analytics Lead	Alguien que traduzca necesidades de negocio en especificaciones de datos
Proceso de data governance	Revisión regular de calidad, ownership y SLAs de datos
Budget herramientas Fase 3	Si Athena se satura: Redshift Serverless (~\$0.36/RPU-hora). QuickSight embedded (~\$0.30/sesión)

¿Qué NO sabemos todavía?

Requiere completar en BD (ver sección Volumetría Real)

Información	Por qué importa
Volumen real de anotaciones	Dimensionar el Data Lake y proyectar costos de Athena
Crecimiento mensual histórico	Proyectar capacidad y decidir si Athena o Redshift
Distribución real de tipos de eventos	Validar hipótesis de uso y priorizar tracking
Usuarios activos reales (30/90/180 días)	Baseline real para North Star Metrics
Instituciones en riesgo de churn (top 20)	Acción inmediata para CS

Requiere entrevistas

Información	Con quién
Modelo de pricing	Finance / CEO
Proceso de renovación y señales de churn	Customer Success
Qué métricas usa Sales para cerrar	Sales
OKRs del año	CEO / CTO
Roadmap de producto	Product Manager

Requiere acceso a herramientas

Herramienta	Datos buscados
HubSpot	Contratos, deals, renovaciones, pipeline
Google Analytics	Confirmar uso y configuración
New Relic	Performance y endpoints críticos
Sentry	Errores frecuentes e impacto
Sistema de billing	Planes, montos, fechas por cliente

Executive Recommendation

Hypothesis posee una base tecnológica sólida, integraciones operativas con los principales LMS del mercado educativo, y un modelo de datos maduro. La infraestructura no es el problema.

El problema es que hoy la compañía no puede responder la pregunta más importante para cualquier conversación de renovación: **¿cuánto valor genera Hypothesis para esta universidad?**

Este assessment identifica tres acciones críticas a tomar en los próximos 30 días, antes de cualquier decisión de inversión mayor:

- 1. Completar la Volumetría Real** (1 día de trabajo): Ejecutar las 10 queries de la sección correspondiente. Sin números reales, este diagnóstico es una hipótesis, no una base para pedir presupuesto al CEO.
- 2. Archivar LTI params a S3 antes del próximo purge** (2-3 días de trabajo, un solo ingeniero): Cada 30 días se ejecuta una tarea que destruye permanentemente el contexto histórico de los eventos. La próxima ejecución puede ocurrir en días. El costo de preservar estos datos es ~\$2-5/mes en S3. El costo de no hacerlo es perder para siempre la capacidad de construir reportes YoY. Esta es la única acción verdaderamente irreversible del roadmap.
- 3. Dashboard proxy de CS** (1-2 semanas): No se necesita DW ni tracking para que CS tenga visibilidad. Los datos en `lms.event` y `lms.application_instances` ya permiten identificar instituciones en riesgo hoy. Metabase conectado a una RDS read replica resuelve esto sin nueva infraestructura.

A mediano plazo: La inversión en el sistema de tracking completo (Fase 1) y el Data Layer AWS-native (Fase 2) está justificada por tres riesgos de revenue concretos: (1) churn no detectado, (2) renovaciones negociadas sin evidencia, (3) decisiones de producto sin datos. Con ~\$50/mes de infraestructura adicional y 2 ingenieros durante 3-5 meses, Hypothesis puede tener dashboards operativos de CS y un Data Lake con datos históricos — una inversión mínima para el riesgo que mitiga.

El diferenciador estratégico de largo plazo es convertir las anotaciones en Learning Analytics: métricas de engagement intelectual que los LMS tradicionales no pueden proveer. Esta es la propuesta de valor que transforma Hypothesis de "herramienta de anotación" a "plataforma de evidencia de aprendizaje activo" — con implicaciones directas en pricing, retención y diferenciación competitiva.

Apéndice — Plan de acción detallado

Semana 1 (inmediata):

- ☒ Ejecutar 10 queries de Volumetría Real en producción
- ☒ Implementar S3 cold archive para LTI params (no esperar al próximo purge)
- ☒ Solicitar acceso a HubSpot
- ☒ Agendar entrevistas: Finance, Sales, CS, Product, CEO

Semana 2-3:

- Dashboard proxy de CS desde datos existentes (Metabase → RDS read replica)
- Resource tracking en client (2-3 días)
- Diseño del sistema de eventos: taxonomía + arquitectura write-path

Sprint 1 (semana 3-6):

- Analytics endpoint correcto: SQS + tabla dedicada + client batching
- Session tracking (parte del sistema de eventos)

Mes 2 (paralelo):

- AWS DMS replication RDS → S3
- Estructura del Data Lake (particionado)
- dbt models iniciales (staging layer)

Mes 3-4:

- dbt business layer (modelo estrella completo)
- Pipeline HubSpot → S3
- Metabase sobre Athena operativo
- **CS tiene dashboard real de churn en mes 4**

Mes 5-8:

- Dashboard institucional para clientes
- Health Score automatizado
- Dashboard de instructores embedded

Mes 9-12:

- Predicción de churn (ML)

- Learning Analytics metrics
- Self-Service Analytics